

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ  
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ  
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук  
Образовательная программа «Прикладная математика и информатика»

**Отчет об исследовательском проекте на тему:**  
**Предсказание спроса на кредитные продукты**

**Выполнил:**

студент группы БПМИ234  
Русанова Маргарита Игоревна

01.04.2025

*(дата)*

**Принял руководитель проекта:**

Богущий Денис Александрович  
Научный сотрудник / аспирант  
Проектно-учебная лаборатория «Искусственный интеллект в математических финансах»

**Москва 2025**

# Содержание

|                                                     |           |
|-----------------------------------------------------|-----------|
| <b>Аннотация</b>                                    | <b>4</b>  |
| <b>1 Введение</b>                                   | <b>4</b>  |
| 1.1 Описание предметной области                     | 4         |
| 1.2 Постановка задачи и результаты                  | 4         |
| 1.3 Структура работы                                | 5         |
| <b>2 Обзор литературы</b>                           | <b>5</b>  |
| <b>3 Работа с данными</b>                           | <b>6</b>  |
| 3.1 Описание данных                                 | 6         |
| 3.2 Предобработка данных                            | 9         |
| 3.3 Корреляции между переменными                    | 11        |
| 3.4 Корреляции переменных со спросом на продукты    | 12        |
| <b>4 Факторный анализ</b>                           | <b>12</b> |
| 4.1 Факторный анализ методом главных осей           | 13        |
| 4.2 Оценка количества факторов                      | 14        |
| 4.3 Факторный анализ в контексте задачи спроса      | 14        |
| 4.3.1 Факторный анализ для прогнозирования ипотек   | 14        |
| 4.3.2 Факторный анализ для прогнозирования кредитов | 15        |
| <b>5 Dynamic Factor Model</b>                       | <b>15</b> |
| 5.1 Общее описание модели DFM                       | 15        |
| 5.2 Компоненты DFM                                  | 16        |
| 5.2.1 Динамическая форма записи DFM                 | 16        |
| 5.2.2 Статическая форма записи DFM                  | 16        |
| 5.3 Начальные параметры DFM                         | 17        |
| 5.3.1 Метод Пауэлла                                 | 17        |
| 5.3.2 Метод Нелдера-Мида                            | 17        |
| 5.4 Корректировка DFM                               | 18        |
| 5.4.1 Фильтр Калмана                                | 18        |
| 5.5 Применение DFM                                  | 19        |
| 5.5.1 Макроэкономический мониторинг                 | 19        |
| 5.5.2 Макроэкономическое прогнозирование            | 20        |
| 5.6 DFM в контексте задачи спроса                   | 20        |
| 5.6.1 Предсказание спроса на ипотеки                | 21        |
| 5.6.2 Предсказание спроса на кредиты                | 21        |
| <b>6 Vector AutoRegression</b>                      | <b>22</b> |
| 6.1 Общее описание модели                           | 22        |
| 6.2 Компоненты VAR                                  | 23        |
| 6.2.1 Динамическая форма записи VAR                 | 23        |
| 6.2.2 Статическая форма записи VAR                  | 23        |
| 6.3 Подбор количества лагов для VAR                 | 23        |
| 6.3.1 Информационный критерий Акаике                | 24        |

|           |                                                               |           |
|-----------|---------------------------------------------------------------|-----------|
| 6.3.2     | Информационный критерий Байеса . . . . .                      | 24        |
| 6.4       | VAR в контексте задачи спроса . . . . .                       | 24        |
| 6.4.1     | Предсказание спроса на ипотеки . . . . .                      | 25        |
| 6.4.2     | Предсказание спроса на кредиты . . . . .                      | 25        |
| <b>7</b>  | <b>Сравнение VAR и DFM</b>                                    | <b>26</b> |
| 7.1       | Теоретический подход . . . . .                                | 26        |
| 7.2       | Сравнение в контексте задачи прогнозирования спроса . . . . . | 27        |
| <b>8</b>  | <b>Заключение</b>                                             | <b>27</b> |
| <b>9</b>  | <b>Используемая терминология</b>                              | <b>28</b> |
| <b>10</b> | <b>Источники</b>                                              | <b>29</b> |

# Аннотация

В данной работе изучаются методы работы с временными рядами, а также решается задача предсказания спроса на кредитные продукты под действием макроэкономических показателей: подробно описывается подбор данных, факторный анализ, имплементации Dynamic Factor Model и Vector AutoRegression, а также проводится сравнение двух этих моделей.

**Ключевые слова:** Dynamic Factor Model, Vector AutoRegression, факторный анализ, макроэкономика, кредитные продукты, временные ряды

## 1. Введение

### 1.1. Описание предметной области

Анализ и предсказание спроса на банковские продукты (такие как кредиты и ипотеки) в зависимости от изменений в макроэкономической среде имеют особое прикладное значение: полученные прогнозы могут помочь банкам в стратегическом планировании и использоваться в процессах адаптации стратегий к изменяющимся во времени условиям рынка.

### 1.2. Постановка задачи и результаты

В рамках работы была поставлена задача изучения и описания методологий для предсказания временных рядов с последующими формулировками моделей, адаптированных для предсказания спроса на кредитные продукты в зависимости от показателей макроэкономики. В итоге выполнено:

1. Сбор внешних данных по открытым источникам
2. Предобработка данных и поиск корреляций
3. Описание и применение принципов факторного анализа
4. Описание принципов работы Dynamic Factor Model
5. Спецификация DFM для задачи о спросе на кредитные продукты
6. Описание принципов работы Vector AutoRegression
7. Спецификация VAR для задачи о спросе на кредитные продукты
8. Теоретическое сравнение DFM и VAR
9. Сравнение моделей на реальных данных

### 1.3. Структура работы

Работа представляет собой параллельный обзор теории по методам прогнозирования временных рядов и её практическое применение в контексте задачи предсказания спроса на кредитные продукты:

1. Во второй секции произведён краткий обзор используемой литературы.
2. В третьей секции проведена подготовка данных, на которых будет осуществляться практическое применение методов.
3. В четвёртой секции рассмотрен факторный анализ, который в этой же секции применён на реальных данных.
4. В пятой секции описана модель DFM и сопутствующие ей методы, а также выполнена имплементация на реальных данных.
5. В шестой секции описана модель VAR и сопутствующие ей методы, а также выполнена имплементация на реальных данных.
6. В седьмой секции проведено теоретическое сравнение VAR и DFM и сравнение полученных практических результатов.
7. В восьмой секции сделаны заключительные выводы работы.
8. Ссылка на репозиторий с кодом: [\[14\]](#)

## 2. Обзор литературы

1. Теория, посвящённая принципам работы DFM, VAR и их применениям была изучена по исследованию [\[1\]](#) Стока и Уотсона, посвящённому динамическим факторным моделям и авторегрессиям в макроэкономике.
2. Для формулирования Dynamic Factor Model, адаптированной под задачу, была изучена документация [\[2\]](#) библиотеки statsmodels, где особое внимание было уделено модулям multivariate и api.
3. Также были изучены параграфы [\[3\]](#) и [\[4\]](#) Тихонова и Вильховенко, размещённые в хендбуке по прикладному анализу данных и посвящённые факторному анализу и его реализации в Python.
4. Для подробного ознакомления с принципами работы фильтра Калмана, используемого для корректировки DFM была изучена статья [\[5\]](#) Истомина, Каламбет, Колбиной, Сидоренко и Яготинцевой.
5. Для изучения макроэкономических тенденций (и, в частности, особенностей циклов Жюгляра) были рассмотрены главы учебника [\[6\]](#) Мокичева, Малаева, Котенковой, Галлямовой и Мокичева.

6. Для понимания концепции скрытых факторов, на которой основывается Dynamic Factor Model, была изучена работа [8] Бернса и Митчелла, в которой идёт речь о бизнес-циклах — ненаблюдаемых процессах.
7. Также для понимания концепции, на которой основывается Vector AutoRegression, была изучена работа [9] Симса, в которой идёт речь о переменных как о равноправных компонентах динамической системы.
8. Для работы с параметрами DFM рассмотрены работы [10] Пауэлла и [11] Нелдера-Мида, благодаря которым становятся понятны авторские методы для подбора начальных параметров.
9. Также как пример наукастинга с помощью DFM рассмотрена работа [12] Джанноне, Райхлин и Смолла и как пример форекастинга рассмотрена работа [13] Эйкмейера и Циглера.

## 3. Работа с данными

### 3.1. Описание данных

Было решено работать с данными FRED [7] (в силу простоты интеграции в Python) за период с 1979 — 01 — 01 по 2024 — 01 — 01. В качестве данных для предиктов взяты следующие факторы:

- банковский кредит по всем коммерческим банкам (TOTBKCR)
- ипотеки — кредиты на недвижимость (RELACBW027SBOG)




Рис. 3.1. Тенденции спроса на банковские продукты

В качестве макроэкономических переменных, от которых гипотетически может зависеть спрос на кредитные продукты, был рассмотрен следующий набор данных, включающий в себя 31 макроэкономический показатель и один показатель, рассчитанный как разность между ставками:

| Макроэкономические показатели |                     |                                                                                        |
|-------------------------------|---------------------|----------------------------------------------------------------------------------------|
|                               | Название на FRED    | Описание                                                                               |
| 1                             | DSPIC96             | Реальный располагаемый личный доход                                                    |
| 2                             | GDP                 | Валовой внутренний продукт                                                             |
| 3                             | UNRATE              | Уровень безработицы                                                                    |
| 4                             | USPHCI              | Совпадающий индекс экономической активности                                            |
| 5                             | INDPRO              | Индекс промышленного производства                                                      |
| 6                             | PAYEMS              | Все наемные работники в несельскохозяйственных отраслях                                |
| 7                             | CPILFESL            | Индекс потребительских цен без учета продуктов питания и энергии                       |
| 8                             | FEDFUNDS            | Эффективная ставка по федеральным фондам                                               |
| 9                             | DPRIME              | Изменения базовой процентной ставки по кредитам                                        |
| 10                            | DGS5                | Рыночная доходность казначейских ценных бумаг США с постоянным сроком погашения 5 лет  |
| 11                            | IR3TCD01USM156N     | Процентные ставки по депозитам                                                         |
| 12                            | PSAVERT             | Ставка личных сбережений                                                               |
| 13                            | UMCSENT             | Индекс потребительских настроений                                                      |
| 14                            | GS10                | Рыночная доходность казначейских ценных бумаг США с постоянным сроком погашения 10 лет |
| 15                            | DTB3                | Доходность 3-месячных казначейских векселей                                            |
| 16                            | PCE                 | Личные потребительские расходы                                                         |
| 17                            | A053RC1Q027SBEA     | Корпоративная прибыль до налогообложения                                               |
| 18                            | BOGZ1FL075035503Q   | Индекс цен на коммерческую недвижимость                                                |
| 19                            | RRVRUSQ156N         | Коэффициент вакантных площадей                                                         |
| 20                            | MSPUS               | Средняя цена продажи домов                                                             |
| 21                            | HOUST               | Количество единиц новых частных жилых домов                                            |
| 22                            | HSN1F               | Количество продаж новых частных домов                                                  |
| 23                            | WTISPLC             | Спотовая цена на сырую нефть                                                           |
| 24                            | BOGMBASE            | Денежная база                                                                          |
| 25                            | CORESTICKM159SFRBAT | Индекс потребительских цен                                                             |
| 26                            | CPIAUCSL            | Индекс потребительских цен для всех городских потребителей                             |
| 27                            | PCEPI               | Цепной индекс цен                                                                      |
| 28                            | M2SL                | Денежная масса M2                                                                      |
| 29                            | POPTHM              | Рост населения                                                                         |
| 30                            | CIVPART             | Уровень участия в рабочей силе                                                         |
| 31                            | LFWA64TTUSM647S     | Население трудоспособного возраста (15-64 года)                                        |
| 32                            | ФИЧА                | Разность DPRIME и FEDFUNDS                                                             |

Рис. 3.2. Описания рассмотренных макроэкономических переменных




Рис. 3.3. Тенденции рассмотренных макроэкономических переменных



## 3.2. Предобработка данных

Необходимый этап работы с данными — это приведение их к удобному и скорректированному виду, так что были выполнены следующие пункты:

1. Поквартильная агрегация по последнему доступному значению для приведения всех временных рядов к единой частоте наблюдений.
2. Преобразование всех макроэкономических показателей, являющихся индексами или выраженными процентами, в две переменных: исходный вид и разность между двумя соседними значениями для явного отслеживания изменений.
3. Преобразование остальных макроэкономических показателей в переменные, равные разности между двумя соседними значениями.
4. Отсечение выбросов по правилу «трёх сигма».
5. Нормализация переменных в рамках 13-летних окон для ипотек и в рамках 12-летних окон для банковских кредитов по следующей формуле:  $x_{ij} \rightarrow \frac{100 \ln(x_{ij}) - 100 \ln(x_j)}{\sigma(100 \ln(x_j))}$ , где  $x_j$  — вектор значений за  $n$  лет  $j$ ой переменной, а  $i$  — некоторый момент времени.

**Пояснение:** В качестве окна мы выбираем промежуток в 12 – 13 лет, что вполне согласуется с возможным значением цикла Жюгляра в США. Другими словами, мы учитываем длину среднесрочного экономического цикла, включающего в себя подъём, пик, рецессию и депрессию.




Рис. 3.4. Тенденция спроса на ипотеки (нормализованного по 13 лет)




Рис. 3.5. Тенденции нормализованных по 13-летним окнам переменных




Рис. 3.6. Тенденция спроса на кредиты (нормализованного по 12 лет)

### 3.3. Корреляции между переменными

Для того, чтобы не переобучить модель на нескольких переменных, сильно коррелирующих между собой, была построена тепловая карта на основе корреляции Спирмена, чтобы уловить и нелинейные зависимости.




Рис. 3.7. Корреляции между переменными (нормализованными по 13 лет)

### 3.4. Корреляции переменных со спросом на продукты

Снова была применена корреляция Спирмена и получены 9 переменных, которые коррелируют со спросом на ипотеки с модулем коэффициента  $> 0.25$  и которые будут далее использованы на этапе факторного анализа:

|   | Variable                    | Correlation |
|---|-----------------------------|-------------|
| 0 | STDPSAVERTNotDiff           | -0.521000   |
| 1 | STDUNRATENotDiff            | -0.478700   |
| 2 | STDBOGZ1FL075035503QNotDiff | 0.415200    |
| 3 | STDINDPRONotDiff            | 0.352000    |
| 4 | STDFEDFUNDS                 | 0.312700    |
| 5 | STDDPRIME                   | 0.304600    |
| 6 | STDUMCSENTNotDiff           | 0.301200    |
| 7 | STDUSPHCINotDiff            | 0.288900    |
| 8 | STDIR3TCD01USM156N          | 0.259100    |

Рис. 3.8. Корреляции переменных со спросом на ипотеки

Аналогично были выявлены 7 переменных, которые коррелируют со спросом на кредиты с модулем коэффициента  $> 0.25$ :

|   | Variable             | Correlation |
|---|----------------------|-------------|
| 0 | STDM2SL              | 0.331300    |
| 1 | STDUMCSENTNotDiff    | 0.326200    |
| 2 | STDPAYEMS            | 0.284500    |
| 3 | STDFEDFUNDS          | 0.266800    |
| 4 | STDBOGZ1FL075035503Q | 0.263200    |
| 5 | STDUSPHCI            | 0.253800    |
| 6 | STDPCE               | 0.252100    |

Рис. 3.9. Корреляции переменных со спросом на кредиты

## 4. Факторный анализ

При построении DFM мы предполагаем, что сможем отобрать такие переменные, которые описывают спрос на кредитные продукты как некоторое выражение от них. Так что в рамках факторного анализа мы хотим достичь 2 цели: выделить переменные, лучше всего описывающие желаемые

скрытые факторы и определить, какое количество факторов они описывают.

В общем виде модель факторного анализа представима следующим выражением:  $X = \Lambda F + \epsilon$ , где

- $X$  — матрица наблюдаемых переменных
- $\Lambda$  — матрица факторных нагрузок
- $F$  — матрица скрытых факторов
- $\epsilon$  — матрица ошибок

## 4.1. Факторный анализ методом главных осей

Метод главных осей заключается в минимизации разницы между ковариационной матрицей  $\Sigma$  и выражением  $\Lambda\Lambda^T + \Psi$  следующим алгоритмом:

1. Считаем значение  $\Sigma$  по наблюдаемым данным
2. Находим начальное приближение  $\Psi^{(0)} = \text{diag}(\Sigma)$
3. Вычисляем редуцированную ковариационную матрицу:  $\Sigma^* = \Sigma - \Psi^{(0)}$
4. Вычисляем собственные значения и векторы матрицы  $\Sigma^*$  и выбираем  $k$  наибольших собственных значений (и соответствующих векторов)
5.  $\Lambda^{(t)} = V_k \sqrt{D_k}$ , где  $V_k$  — матрица собственных векторов, а  $D_k$  — диагональная матрица собственных значений
6. Обновляем  $\Psi^{(t)} = \text{diag}(\Sigma - \Lambda^{(t)}(\Lambda^{(t)})^T)$  и  $\Sigma^* = \Sigma - \Psi^{(t)}$
7. Повторяем с 4 пункта, пока изменения в  $\Lambda$  и  $\Psi$  не станут меньше заданных в начале значений

**Реализация:** в модуле *multivariate* библиотеки *statmodels* хранится класс *Factor*, реализующий методы факторного анализа. Необходимо создать экземпляр класса *Factor*, передать данные, желаемое количество факторов и указать метод главных осей, а затем применить *fit()*:

```
1 from statsmodels.multivariate.factor import Factor
2 factor = Factor(Data, n_factor, method='pa')
3 result = factor.fit()
```

Для интерпретации результатов удобно использовать *get\_loadings\_frame()*, чтобы вывести сгруппированную таблицу факторных нагрузок:

```
4 result.get_loadings_frame(threshold=0.3)
```

## 4.2. Оценка количества факторов

Для оценки оптимального количества скрытых факторов существует критерий Кайзела, заключающийся в следующем:

1. Строим график собственных значений  $\Lambda$
2. Количество факторов соответствует числу собственных значений  $> 1$

**Реализация:** удобно использовать график `plot_scree()`, который применяется к уже полученному ранее `result`:

```
1 import matplotlib.pyplot as plt
2 result.plot_scree()
3 plt.show()
```

## 4.3. Факторный анализ в контексте задачи спроса

### 4.3.1. Факторный анализ для прогнозирования ипотек

Проведя описанный анализ на наших данных, видим, что отобранные ранее переменные явно задают два ненаблюдаемых фактора. Выбран был тот, который прослеживается более ярко (имеет наибольшее собственное значение) и было сделано предположение в силу подбора переменных, что именно он и соответствует спросу на ипотеки. Далее были выявлены 6 переменных, которые коррелируют с этим фактором с модулем коэффициента  $> 0.3$  и которые будут рассматриваться в качестве входных данных модели:




Рис. 4.1. Факторный анализ для предсказания спроса на ипотеки

### 4.3.2. Факторный анализ для прогнозирования кредитов

В данном случае мы видим только один явно выраженный ненаблюдаемый фактор и делаем предположение, что он и соответствует спросу на кредиты. Аналогично были выявлены 6 переменных, являющихся потенциальными входными данными модели:




Рис. 4.2. Факторный анализ для предсказания спроса на кредиты

## 5. Dynamic Factor Model

### 5.1. Общее описание модели DFM

Dynamic Factor Model основывается на свойстве, что общее поведение множества временных рядов объяснимо с помощью ограниченного числа ненаблюдаемых факторов, изменяющихся во времени.

Концепция скрытых факторов восходит к работе [8] Бернса и Митчелла, которые эмпирически показали, что совместные движения множества макроэкономических временных рядов обусловлены единым ненаблюдаемым процессом, названным бизнес-циклом. А непосредственное введение DFM в макроэкономику для анализа и прогнозирования бизнес-циклов состоялось благодаря работам [1] Стока и Уотсона.

Для DFM свойственно следующее:



1. **Эффективное сжатие информации:** всего несколько скрытых факторов способны охарактеризовать изменения большого количества временных рядов.
2. **Соответствие теории динамического равновесия:** ограничение на небольшое количество скрытых факторов согласуется с современными макроэкономическими теориями.

## 5.2. Компоненты DFM

Dynamic Factor Model представляет собой изменения вектора из  $N$  временных рядов, обозначаемые как  $X_t$ . При этом для разных целей может использоваться как динамическая форма записи DFM, так и статическая.

### 5.2.1. Динамическая форма записи DFM

Динамическая форма в основном используется для моделирования временных рядов и прогнозирования:  $X_t = \lambda(L)f_t + e_t$ , где  $f_t = \Psi(L)f_{t-1} + \eta_t$

- $X_t \in R^N$  — вектор наблюдаемых переменных в момент времени  $t$
- $f_t \in R^r$  — вектор скрытых факторов в момент времени  $t$
- $e_t \in R^N$  — вектор идиосинкратических возмущений
- $\eta_t \in R^r$  — вектор шоков, связанных с  $f_t$
- $L$  — оператор запаздывания ( $L^k X_t = X_{t-k}$ )
- $\lambda_k \in R^{N \times r}$  — матрица факторных нагрузок для лага  $k$
- $\lambda(L) = \sum_{k=0}^p \lambda_k L^k$ , где  $p$  — максимальный лаг
- $\Psi_k \in R^{r \times r}$  — матрица коэффициентов авторегрессии для лага  $k$
- $\Psi(L) = \sum_{k=1}^q \Psi_k L^k$ , где  $q$  — порядок авторегрессии для факторов

### 5.2.2. Статическая форма записи DFM

Статическая форма переписывает динамическую так, чтобы она зависела от  $r$  статических факторов вместо  $q$  динамических (другими словами, это state-space представление динамической формы, где  $F_t$  объединяет текущие и лагированные факторы):  $X_t = \Lambda F_t + e_t$ , где  $F_t = \Phi F_{t-1} + G\eta_t$

- $F_t = (f_t^\top, f_{t-1}^\top, \dots, f_{t-p}^\top)^\top \in R^r$
- $\Lambda = (\lambda_0, \lambda_1, \dots, \lambda_p)$  — блочная матрица факторных нагрузок



- $\Phi = \begin{pmatrix} \Psi_1 & \Psi_2 & \cdots & \Psi_p & 0 \\ I_q & 0 & \cdots & 0 & 0 \\ 0 & \ddots & \ddots & \vdots & \vdots \\ 0 & \cdots & I_q & 0 & 0 \end{pmatrix} \in R^{r \times r}$  — матрица переходов

- $G^\top = (I_q \ 0 \ \cdots \ 0) \in R^{r \times q}$  — матрица шоков

**Реализация:** в модуле *api* библиотеки *statsmodels* содержится модель *DynamicFactorMQ*, в которую обязательно передаются временные ряды, описывающие скрытый фактор:

```
1 import statsmodels.api as sm
2 DFM = sm.tsa.DynamicFactorMQ(endog)
```

### 5.3. Начальные параметры DFM

Чтобы модель выдавала хорошие предикты, необходимо предварительно оценить её параметры: для этого необходимо максимизировать функцию правдоподобия  $L(\theta)$ , которая, по сути, является вероятностью наблюдать данные  $Y$  при параметрах модели  $\theta$ . Ниже рассмотрим методы, в которых мы минимизируем  $-\log L(\theta)$ , что соответствует максимизации  $L(\theta)$ :

#### 5.3.1. Метод Пауэлла

Метод Пауэлла минимизирует  $-\log L(\theta)$  путем последовательного поиска вдоль сопряжённых направлений с помощью следующего алгоритма:

1. Задаем начальные значения параметров  $\theta_{initial}$  и начальные направления поиска  $d_1, d_2, \dots, d_n$
2. Минимизируем  $-\log L(\theta)$  вдоль каждого  $d_i$ :  $\alpha_i = \arg \min_{\alpha} (-\log L(\theta + \alpha d_i))$ , где  $\alpha_i$  — шаг минимизации, и обновляем  $\theta \leftarrow \theta + \alpha_i d_i$
3. Добавляем к направлениям  $d_{n+1} = \theta_{current} - \theta_{initial}$  и удаляем  $d_1$
4.  $\alpha_{n+1} = \arg \min_{\alpha} (-\log L(\theta + \alpha d_{n+1}))$  и обновляем  $\theta \leftarrow \theta + \alpha_{n+1} d_{n+1}$
5. Перенумеровываем  $d_i$ , делаем  $\theta_{initial} = \theta_{current}$  и повторяем со 2 пункта, пока изменения  $\theta$  или  $-\log L(\theta)$  не станут меньше зафиксированных в начале ограничений.

#### 5.3.2. Метод Нелдера-Мида

Метод Нелдера-Мида минимизирует  $-\log L(\theta)$ , используя симплекс — геометрическую фигуру в  $n$ -мерном пространстве с  $n + 1$  вершиной:

1. Задаем начальные значения параметров  $\theta_{initial}$  и строим некоторый начальный симплекс

2. Вычисляем  $-\log L(\theta)$  в каждой вершине симплекса и сортируем вершины по возрастанию значений функции
3. Вычисляем центр тяжести всех вершин, кроме  $\theta_{n+1}$  (имеющей наибольшее значение функции):  $\theta_c = \frac{1}{n} \sum_{i=1}^n \theta_i$
4. Вычисляем  $\theta_r = \theta_c + \alpha(\theta_c - \theta_{n+1})$ , где  $\alpha$  — коэффициент отражения
5. Если  $-\log L(\theta_r) < -\log L(\theta_1)$ , то вычисляем  $\theta_e = \theta_c + \gamma(\theta_r - \theta_c)$ , где  $\gamma$  — коэффициент расширения. Если  $-\log L(\theta_e) < -\log L(\theta_r)$ , то  $\theta_{n+1} \rightarrow \theta_e$ , иначе же  $\theta_{n+1} \rightarrow \theta_r$ .
6. Если же  $-\log L(\theta_r) \geq -\log L(\theta_n)$ , то вычисляем  $\theta_s = \theta_c + \rho(\theta_{n+1} - \theta_c)$ , где  $\rho$  — коэффициент сжатия. Если  $-\log L(\theta_s) < -\log L(\theta_{n+1})$ , то  $\theta_{n+1} \rightarrow \theta_s$ , иначе же выполняем редукцию:  $\theta_i = \theta_1 + \sigma(\theta_i - \theta_1)$ , где  $\sigma$  — коэффициент редукции.
7. Повторяем со 2 пункта, пока изменения  $-\log L(\theta)$  или размер симплекса не станут меньше зафиксированных в начале ограничений.

Стандартные коэффициенты:  $\alpha = 1, \gamma = 2, \rho = 0.5, \sigma = 0.5$

**Реализация:** для того, чтобы подобрать начальные параметры DFM, мы должны применить к ней `fit()` с указанием выбранного метода, а затем при следующем применении `fit()` передать в него подобранные параметры:

```
3 initial_res = DFM.fit(method='x')
4 res = DFM.fit(start_params=initial_res.params)
```

## 5.4. Корректировка DFM

В силу того, что DFM подвержена шумам, содержащимся в данных, ей необходима корректировка. Для этого существует двухфазный рекурсивный алгоритм фильтра Калмана, позволяющий сгладить шумы.

### 5.4.1. Фильтр Калмана

В первой фазе алгоритм прогнозирует состояние  $F_t$  на основе прошлых данных, а во второй — корректирует прогноз с учётом новых данных  $X_t$ .

#### Фаза предсказания:

- Предсказываем состояние системы:  $\hat{F}_{t|t-1} = \Phi \hat{F}_{t-1|t-1}$
- Предсказываем ошибку ковариации:  $P_{t|t-1} = \Phi P_{t-1|t-1} \Phi^\top + G Q G^\top$ , где  $Q$  — ковариационная матрица шума процесса

#### Фаза корректировки:

- Вычисляем усиление Калмана:  $\hat{F}_{t|t} = \hat{F}_{t|t-1} + K_t(X_t - \Lambda \hat{F}_{t|t-1})$

- Обновляем  $P_{t|t} = (I - K_t\Lambda)P_{t|t-1}$

**Реализация:** для того, чтобы скорректировать DFM фильтром Калмана, достаточно применить метод `filter()` и передать в него ранее полученные параметры модели:

```
5 res = mod.filter(params=res.params)
```

## 5.5. Применение DFM

Классическими областями применения моделей динамических факторов является макроэкономический мониторинг и прогнозирование.

### 5.5.1. Макроэкономический мониторинг

Макроэкономическом мониторинг разбивается на две задачи: построение индексов, резюмирующих доступные данные экономических условий, и наукастинг — предсказание текущего значения конкретного ряда данных, который еще не был опубликован.

#### Построение индексов для резюме условий

Уже знаем, что в DFM скрытые факторы обобщают совместные движения наблюдаемых временных рядов, а если такой фактор один — его называют индексом. Ярким примером использования DFM в таком ключе является экспериментальный совпадающий индекс (ХСИ), построенный Стоком и Уотсоном. ХСИ представлял собой скрытый фактор, начальные параметры которого оценивались методов Пауэлла и который задают 4 переменные:

1. Индекс промышленного производства
2. Реальный личный доход (в миллиардах)
3. Реальные продажи в сфере производства и торговли (в миллионах)
4. Количество работников несельскохозяйственного сектора

Долгое время ХСИ успешно справлялся с текущим мониторингом и предсказывал рецессии, однако в 1993 ХСИ и сопутствующий ему индекс не смогли спрогнозировать рецессию на 6-месячном горизонте.

#### Краткосрочное прогнозирование (наукастинг)

Задача наукастинга — прогнозирование текущего значения наблюдаемых переменных, допускающее использование данных смешанной частоты и прерывистые публикации. Хорошим примером наукастинга является работа Джанноне, Райхлин и Смолла, в которой авторы занимаются наукастингом внутреннего валового продукта.

Особенностью работы является использование действительно огромного количества данных — порядка 200 временных рядов, описывающих экономику США. В работе описывается решение проблемы «рваного края» и применяются следующие методы:

1. Извлечение главных компонент путём факторного анализа
2. Оценка параметров модели с помощью МНК-регрессии
3. Применение фильтра Калмана

### **5.5.2. Макроэкономическое прогнозирование**

Dynamic Factor Model позволяет решать и задачи долгосрочного прогнозирования, в которых также допускает использование данных смешанной частоты и прерывистые публикации. В данном случае весьма интересные результаты можем наблюдать в работе [13] Эйкмейера и Циглера.

В их работе проведен анализ порядка 50 исследований, сравнивающих предикты DFM с предиктами других моделей: AR, VAR и прочих. Для некоторых показателей было зафиксировано снижение ошибки RMSE на 15–25% именно при использовании DFM. Наилучшие результаты достигались при использовании следующего:

1. Включении достаточно большого числа предикторов
2. Прогнозировании вперёд на 1-2 квартала
3. Комбинации hard (измеряемых физически) и soft (основанных на мнениях, ожиданиях или косвенных индикаторах) данных

## **5.6. DFM в контексте задачи спроса**

Для специализации DFM под задачу предсказания спроса на ипотеки и кредиты было выполнено следующее:

- Выставлено нижнее ограничение на количество переменных во входных данных модели = 4 и осуществлён перебор по всем возможным наборам отобранных ранее переменных
- Осуществлён перебор методов подбора начальных параметров
- Лучшая модель выбрана посредством вычисления ошибки MAE
- Применён фильтр Калмана
- К полученному в результате модели фактору подобран корректирующий коэффициент в диапазоне от 0.9 до 1.1.

### 5.6.1. Предсказание спроса на ипотеки

Получилось, что лучше всего спрос на ипотеки описывает модель, опирающаяся на метод Пауэлла и получающая на вход следующие переменные со следующими коэффициентами:




Рис. 5.1. Коэффициенты переменных модели

- STDPSAVERTNotDiff — ставка личных сбережений
- STDUNRATENotDiff — уровень безработицы
- STDBOGZ1FL075035503QNotDiff — индекс цен на коммерческую недвижимость
- STDUMCSENTNotDiff — индекс потребительских настроений

В итоге, был получен фактор, который довольно хорошо описывает восходящие-нисходящие тренды спроса на ипотеки и даже учитывает небольшие колебания. Фактор не имеет резких пиков и скачков как непосредственно сам спрос, но ошибка MAE составляет  $0.65 \sim 11\%$  от диапазона значений спроса, что является весьма неплохим результатом.




Рис. 5.2. Сравнение спроса на ипотеки и полученного фактора

### 5.6.2. Предсказание спроса на кредиты

Для спроса на кредиты лучше подошёл метод Нелдера-Мида и следующие переменные со следующими коэффициентами:




Рис. 5.3. Коэффициенты переменных модели

- STDM2SL — денежная масса M2 (разность между соседними значениями)
- STDUMCSENTNotDiff — индекс потребительских настроений
- STDPAVEMS — все наёмные работники в несельскохозяйственных отраслях (разность между соседними значениями)
- STDPCE — личные потребительские расходы (разность между соседними значениями)

Также получили фактор, который довольно неплохо (за исключением периода 2020-2024) описывает восходящие-нисходящие тренды спроса на кредиты, но который опять-таки не отражает пиковые значения и резкие скачки. Ошибка MAE составляет  $0.78 \sim 11\%$  от диапазона значений спроса, что опять-таки является неплохим результатом.




Рис. 5.4. Сравнение спроса на кредиты и полученного фактора

## 6. Vector Autoregression

### 6.1. Общее описание модели

Vector Autoregression описывает совместную динамику нескольких временных рядов и основывается на том, что каждый временной ряд зависит от собственных лагов и от лагов других рядов. Особенностью VAR является симметричность, означающая что все переменные являются равноправными: отсутствует деление на экзогенные и эндогенные переменные.

Концепция VAR восходит к работе [9] Симса, который полностью переосмыслил подход к моделированию временных рядов, перестав делить переменные на экзогенные и эндогенные и эмпирически показав, что большинство переменных стоит рассматривать как равноправные компоненты единой динамической системы. А непосредственная адаптация VAR для кредитно-денежной политики опять-таки состоялась в работах [1] Стока и Уотсона (стоит отметить, что VAR может быть как самостоятельной моделью для предсказания временных рядов, так и, например, решать проблему «рваного края» для последующего применения DFM).

## 6.2. Компоненты VAR

### 6.2.1. Динамическая форма записи VAR

Динамическая форма записи базовой VAR модели используется для анализа вклада каждого лага:  $Y_t = c + A_1 Y_{t-1} + A_2 Y_{t-2} + \dots + A_p Y_{t-p} + \varepsilon_t$

- $Y_t = (y_{1,t}, y_{2,t}, \dots, y_{n,t})^\top$  — вектор переменных
- $c \in R^n$  — вектор констант
- $A_k \in R^{n \times n}$  — матрицы коэффициентов
- $\varepsilon_t \in R^n$  — вектор ошибок

### 6.2.2. Статическая форма записи VAR

Статическая форма записи позволяет рассмотреть общую структуру зависимостей, а не только отдельные лаги:  $A(L)Y_t = \eta_t$

- $L$  — оператор лага ( $L^k Y_t = Y_{t-k}$ )
- $A(L) = I - A_1 L - \dots - A_p L^p$  — лаговый полином

**Реализация:** в модуле *api* библиотеки *statsmodels* содержится модель VAR, в которую обязательно передаются временные ряды, между которыми мы хотим установить взаимосвязи:

```
1 from statsmodels.tsa.api import VAR
2 VAR = VAR(data)
```

## 6.3. Подбор количества лагов для VAR

При недостаточном количестве лагов мы получим прогнозы низкой точности, а при избыточном — высокий разброс прогнозов, поэтому важно подобрать оптимальное количество лагов для векторной авторегрессии. Чтобы выбрать оптимальное количество лагов, мы должны зафиксировать параметр *maxlags*, а затем оценить модель одним из следующих критериев.

### 6.3.1. Информационный критерий Акаике

$AIC = 2k - 2 \ln(L)$ , где

- $k$  — количество параметров модели,
- $L$  — максимальное значение функции правдоподобия модели.

### 6.3.2. Информационный критерий Байеса

$BIC = k \ln(n) - 2 \ln(L)$ , где

- $k$  — количество параметров модели,
- $n$  — количество наблюдений (объем выборки),
- $L$  — максимальное значение функции правдоподобия модели.

**Реализация:** для того, чтобы подобрать оптимальное количество лагов для VAR, мы должны применить к ней `select_order()` с указанием максимально возможного количества лагов, а затем у полученного результата обратиться к критерию, по которому будем выбирать лучшую модель:

```
1 order = VAR.select_order(maxlags=n)
2 lags = order.selected_orders['criterion']
```

## 6.4. VAR в контексте задачи спроса

Для специализации VAR под задачу предсказания спроса на ипотеки и кредиты было выполнено следующее:

- Выставлено нижнее ограничение на количество переменных во входных данных модели = 3 (помимо них спрос на рассматриваемый кредитный продукт обязательно включён) и осуществлён перебор по всем возможным наборам отобранных ранее переменных
- На каждом наборе отделена тренировочная выборка (первые 10 лет)
- На тренировочной выборке запущен автоматизированный подбор оптимального количества лагов по критериям AIC и BIC.
- Скользящим окном (10 лет) осуществлён проход по всему временному ряду и каждый раз сделан предикт на один шаг вперёд.
- Лучшая модель выбрана посредством вычисления ошибки MAE



### 6.4.1. Предсказание спроса на ипотеки

Получилось, что лучше всего спрос на ипотеки описывает модель, использующая 1 лаг (отобран по BIC-критерию — на нём была лучше MAE) и основывающаяся на следующих переменных помимо спроса на ипотеки:

- STDPSAVERTNotDiff — ставка личных сбережений
- STDBOGZ1FL075035503QNotDiff — индекс цен на коммерческую недвижимость
- STDUMCSENTNotDiff — индекс потребительских настроений

В итоге, были получены предикты, которые помимо того, что хорошо описывают восходящие-нисходящие тренды спроса на ипотеки, ещё и местами отображает резкие изменения во временном ряду. Ошибка MAE составляет  $0.69 \sim 11\%$  от диапазона значений спроса, что особо не отличается от ошибки, полученной при использовании DFM.




Рис. 6.1. Сравнение спроса на ипотеки и полученного прогноза

### 6.4.2. Предсказание спроса на кредиты

Для предсказания спроса на кредиты лучше всего подошла модель, также использующая 1 лаг (отобран по BIC-критерию — на нём лучшая MAE) и основывающаяся на следующих переменных помимо спроса на кредиты:

- STDUMCSENTNotDiff — индекс потребительских настроений
- STDPAYEMS — все наёмные работники в несельскохозяйственных отраслях (разность между соседними значениями)
- STDUSPHCI — совпадающий индекс экономической активности (разность между соседними значениями)
- STDPCE — личные потребительские расходы (разность между соседними значениями)

Также получили предикты, которые неплохо описывают восходящие-нисходящие тренды спроса на кредиты (за исключением промежутка 2010 — 2012), а также отображают некоторые резкие изменения во временном ряду. Ошибка MAE составляет  $0.69 \sim 10\%$  диапазона значений спроса, что опять-таки особо не отличается от ошибки, полученной при использовании DFM.




Рис. 6.2. Сравнение спроса на кредиты и полученного прогноза

## 7. Сравнение VAR и DFM

### 7.1. Теоретический подход

Как Vector AutoRegression, так и Dynamic Factor Model используются для предсказания значений временных рядов, но модели существенно отличаются в следующих аспектах:

1. **Структура:** в VAR все переменные являются явными, в то время как в DFM мы отслеживаем скрытые факторы.
2. **Интерпретация:** VAR позволяет отследить прямые взаимовлияния переменных друг на друга, а DFM отражает общие тенденции.
3. **Лаги:** в VAR используются собственные лаги и лаги других рядов, а в DFM не используются лаги прогнозируемого ряда.
4. **Размерность:** в VAR мы можем наблюдать «проклятие размерности», в то время как DFM остаётся эффективным на большом количестве рядов.
5. **Устойчивость:** VAR подвержена переобучению на большом количестве переменных, а DFM становится устойчивее в больших системах.

**Примечание:** стоит отметить, что достаточно интересным и эффективным для некоторых задач является следующий подход: сжатие большого количества временных рядов в несколько скрытых факторов с помощью DFM и последующее использование VAR на этих факторах

## 7.2. Сравнение в контексте задачи прогнозирования спроса

Мы получили вполне сопоставимые ошибки в результате задачи предсказания спроса на кредитные продукты с помощью DFM и с помощью VAR, однако явно прослеживается разница в следующем:

1. **Чувствительность к изменениям:** DFM неплохо отображает восходящие-нисходящие тренды, но если мы говорим об отображении резких изменений и скачков, то с этим, безусловно, лучше справляется VAR.
2. **Решаемая задача:** Мы смогли применить DFM в ключе мониторинга, так как использовали переменные, значения которых в момент  $t$  уже известны, а вот с помощью VAR вполне получилось решить задачу прогнозирования, используя только значения предыдущих моментов.




Рис. 7.1. Спрос на ипотеки / скрытый фактор / полученный прогноз




Рис. 7.2. Спрос на кредиты / скрытый фактор / полученный прогноз

## 8. Заключение

В результате проделанной работы были изучены следующие методы работы с временными рядами: факторный анализ, Dynamic Factor Model и Vector AutoRegression, а также задачи, которые они решают. Кроме того, были изучены особенности EDA и предобработки временных рядов, а также проведён сравнительный анализ DFM и VAR.

В действенности методов помогла убедиться их спецификация под задачу предсказания спроса на кредитные продукты. Факторный анализ

использовался как вспомогательный инструмент, а с помощью DFM и VAR строились непосредственно предикты. С учётом специфики и параметров каждой из моделей, на обеих получилось достичь предсказаний, которые характеризуются следующим:

|                   | VAR                                                                                  | DFM                                                                                  |
|-------------------|--------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|
| <b>Ошибка MAE</b> | 11% от диапазона спроса на ипотеки и 10% от диапазона спроса на кредиты              | 11% от диапазона спроса на ипотеки и 11% от диапазона спроса на кредиты              |
| <b>Предикт</b>    | Описывает восходящие и нисходящие тренды, также с запазданием отражает резкие скачки | Описывает восходящие и нисходящие тренды, практически не отображает резкие изменения |
| <b>Переменные</b> | Использовалось 3-4 входных переменных и само значение предсказываемого спроса        | Использовалось 4 входных переменных                                                  |
| <b>Выборка</b>    | Первые 10 лет использовались для обучения и выбора количества лагов                  | Предсказания выполнены на данных за весь рассматриваемый диапазон                    |

Рис. 8.1. Сравнительная таблица имплементированных VAR и DFM

На основе полученных предсказаний можем предположить, что VAR является моделью весьма чувствительной к смене макро-режимов, но её прогнозы являются смещёнными из-за использования прошлых лагов для предсказания настоящего. DFM же в свою очередь отражается преимущественно основные тенденции: рост и рецессию, поскольку несколькими факторами описывает общую динамику данных и не всегда может учесть скачки и их резкость.

Также стоит отметить, что каждая из моделей в контексте предсказания спроса решала свою задачу: с помощью VAR было выполнено прогнозирование на один шаг вперёд, а DFM использовался для макроэкономического мониторинга. Таким образом, выбор оптимального подхода к решению зависит от решаемой задачи. Явная разница заключается в следующем:

| VAR                                                             | DFM                                             |
|-----------------------------------------------------------------|-------------------------------------------------|
| Явные переменные                                                | Скрытые факторы                                 |
| Прямые взаимовлияния переменных друг на друга                   | Общие тенденции данных                          |
| Собственные лаги и лаги других рядов                            | Только лаги других рядов                        |
| Лаги за предыдущие моменты времени                              | Лаги за моменты времени, включая настоящий      |
| Эффективность и устойчивость на небольшом количестве переменных | Эффективность и устойчивость в больших системах |

Рис. 8.2. Главные отличия VAR и DFM

## 9. Используемая терминология

**Теория динамического равновесия** — концепция, описывающая состояние баланса всех компонентов экономики и процесс адаптации системы

к изменениям путём корректировки ключевых переменных.

**Идиосинкратическое возмущение** — специфическое изменение, влияющее только на состояние отдельных экономических групп.

**Макроэкономический шок** — внезапное изменение в экономических условиях, которое способно оказать воздействие на состояние экономики.

**Прерывистые публикации** — данные, не являющиеся монолитным документом и не имеющие фиксированного графика публикации.

**Экзогенные переменные** — переменные, которые определяются вне модели и не зависят от её внутренних механизмов.

**Эндогенные переменные** — переменные, определяющиеся через уравнения модели, подвергающиеся влиянию и влияющие на другие.

**Проклятие размерности** — ухудшение производительности модели по мере увеличения числа переменных, подающихся на вход.

**Проблема «рваного края»** — несовпадение дат последних доступных наблюдений в наборе данных, вызывающее несбалансированности выборки.

## 10. Источники

[1] Watson M. W., Stock J. H. Dynamic Factor Models, Factor-Augmented Vector Autoregressions, and Structural Vector Autoregressions in Macroeconomics. Amsterdam : Elsevier B.V., 2016.

[2] Documentation of the Python module statsmodels [Электронный ресурс]. 2009-2023. URL: <https://www.statsmodels.org> (дата обращения: 29.03.2025).

[3] Метод главных компонент и факторный анализ [Электронный ресурс]. 2024. URL: <https://education.yandex.ru/handbook/data-analysis/article/metod-glavnyh-komponent-i-faktornyj-analiz> (дата обращения: 29.03.2025)

[4] Метод главных компонент и факторный анализ в Python [Электронный ресурс]. 2024. URL: <https://education.yandex.ru/handbook/data-analysis/article/pandan-metod-glavnyh-komponent-i-faktornyj-analiz-v-python> (дата обращения: 29.03.2025).

[5] Истомин Е. П., Каламбет М. В., Колбина О. Н., Сидоренко А. Ю., Яготинцева Н. В. О применении фильтра Калмана при прогнозировании значений параметров природной системы // Информация и космос. 2021.

[6] Мокичев С. В., Малаев В. В., Котенкова С. Н., Галлямова Д. Х., Мокичев С. Д. Экономическая теория. Часть II. М. : Экономистъ, 2011.

[7] Economic data [Электронный ресурс] / Federal Reserve Bank of St. Louis. URL: <https://fred.stlouisfed.org> (дата обращения: 29.03.2025).

[8] Burns A. F., Mitchell W. C. Measuring Business Cycles. NBER, 1946.

[9] Sims C. A. Macroeconomics and Reality // Econometrica. 1980.

[10] Powell M. J. D. An efficient method for finding the minimum of a function of several variables without calculating derivatives // The Computer Journal. 1964.

[11] Nelder J. A., Mead R. A simplex method for function minimization // The Computer Journal. 1965.

[12] Giannone D., Reichlin L., Small D. Nowcasting: The real-time informational content of macroeconomic data // Journal of Monetary Economics. 2008.

[13] Eickmeier S., Ziegler C. How Successful Are Dynamic Factor Models at Forecasting Output and Inflation? A Meta-Analytic Approach // Journal of Forecasting. 2008.

[14] Forecasting Demand [Электронный ресурс] // GitHub. URL: <https://github.com/mirusanova-mirus/ForecastingDemand> (дата обращения: 31.03.2025).